

AI 提示词工程手册

基于知识库资料整理 | 2026 年 8 月

目录

- 提示词工程概述
- 基础提示技巧
- 少量样本 (Few-shot) 提示
- 零样本 (Zero-shot) 提示
- 思维链 (Chain of Thought) 提示
- 角色身份提示
- 检索增强生成 (RAG) 提示
- 上下文长度与提示设计
- 提示词设计最佳实践
- 参考文献

1. 提示词工程概述

1.1 什么是提示词工程

提示词工程 (Prompt Engineering) 是在有限计算预算下，对大型语言模型 (LLM) 进行专门化或改进的最简单策略。它通过精心构造文本序列的开头部分，来偏置自回归生成过程，从而引导模型产生期望的输出。

"Prompt engineering is the simplest strategy to specialize or improve a Large Language Model with a limited computational budget." — Sahoo et al., 2024

这种方法将传统上编码在模型参数中的一部分信息，转移到了输入中。也就是说，不是通过修改模型权重来改变行为，而是通过精心设计的输入来引导模型。

1.2 提示词的工作原理

大型语言模型是通过自回归方式训练的——给定前面出现的 token，预测下一个 token。当模型在非常大的数据集上训练后，它不仅掌握了语言的句法和语法结构，还必须整合非常多样化的知识。例如，它需要能够预测：

- "The capital of Japan is __" → **Tokyo**
- "If water is heated to 100 degrees Celsius it turns into __" → **steam/vapor**

当给定一个精心制作的提示词时，模型能够展现出令人惊讶的能力，包括问答、问题解决和思维链推理，这些能力看起来非常接近高级推理。

1.3 提示词工程的核心思想

提示词的作用是**杠杆式利用训练集中存在的“好”偏置（good biases）**。通过精心构造提示，我们可以：

- 激活模型在训练过程中学到的特定能力
 - 引导模型关注特定知识领域
 - 约束模型输出的格式和风格
 - 在不改变模型参数的情况下实现任务适配
-

2. 基础提示技巧

2.1 清晰指令原则

最基础的提示技巧是给出**清晰、明确、无歧义的指令**。模糊的提示会产生模糊的回答，而精确的提示则能引导模型产出精确的结果。

示例：

模糊提示

“告诉我一些关于 AI 的事”

“写个邮件”

2.2 结构化提示设计

将提示词结构化，有助于模型更好地理解任务要求。推荐的结构包括：

[角色设定]
[任务描述]
[输出格式要求]
[约束条件]
[示例（可选）]

2.3 逐步引导

复杂任务可以拆解为多个步骤，在提示中明确引导模型按步骤执行。

3. 少量样本（Few-shot）提示

3.1 概念

少量样本提示（Few-shot prompting）是指在提示中给出少量示例，让模型学习任务模式，无需微调就能完成特定任务。

大型语言模型在训练过程中，当给定几个示例（few-shot）或仅给出描述任务的指令（zero-shot）时，会发展出解决各种任务的能力。—— Introduction to AI Safety, Ethics, and Society

3.2 工作原理

少量样本提示利用了**上下文学习 (In-context Learning)** 机制。研究表明，上下文学习在行为上近似于随机梯度下降 (SGD) ——当模型接收到更多任务示例时，它会在内部发生一种优化过程，定性改变它正在实现的模型类型。

3.3 案例：情感分类

以下是一个使用 1.2 亿参数 GPT 模型进行少量样本预测的示例：

I: I love apples, O: positive
I: music is my passion, O: positive
I: my job is boring, O: negative
I: frozen pizzas are awesome, O: positive
I: this movie is terrible, O:

模型会预测出 **negative**。

3.4 案例：主题分类

I: water boils at 100 degrees, O: physics
I: the square root of two is irrational, O: mathematics
I: the set of prime numbers is infinite, O: mathematics
I: gravity is proportional to the mass, O: physics
I: squares are rectangles, O:

模型会正确分类为 **mathematics**。

3.5 少量样本提示的关键要点

- **示例质量比数量更重要**：精心挑选的代表性示例，远胜于随机的大量示例
 - **示例格式一致性**：所有示例应保持统一的输入输出格式
 - **示例覆盖范围**：示例应覆盖任务中可能出现的主要模式
 - **示例数量**：通常 3~5 个示例即可获得良好效果
-

4. 零样本 (Zero-shot) 提示

4.1 概念

零样本提示 (Zero-shot prompting) 是少量样本提示的极端版本——不给模型提供任何示例，仅通过任务描述来引导模型执行新任务。

4.2 工作原理

零样本学习测试模型在未提供任何训练示例的情况下，处理全新数据的能力。它依赖于模型利用从已见示例中推导出的数据关系理解，来预测新的、未见过的类别。

“Zero-shot learning often relies on additional information, such as attributes or natural language descriptions of unseen data, to bridge the gap between known and unknown.” — Introduction to AI Safety, Ethics, and Society

4.3 案例

请将以下文本分类为"正面"或"负面"情感：

文本：今天天气真好，适合出去散步。

情感：

4.4 零样本提示的适用场景

- 任务定义清晰、标准明确
 - 无法提供示例（如新类别、新任务）
 - 快速原型验证
 - 简单、标准化的分类任务
-

5. 思维链（Chain of Thought）提示

5.1 概念

思维链提示（Chain of Thought, CoT） 是一种强大的提示技术，旨在让模型在生成最终回答之前，先生成中间推理步骤。

“A remarkable type of prompting aims at making the model generate intermediate steps before generating the response itself.” — The Little Book of Deep Learning

5.2 工作原理

思维链由一系列连续的步骤组成，每个步骤都相对简单，因此在训练过程中被建模得更好，预测也更确定。

5.3 案例对比

以下展示使用 Llama-3-8B 基础模型时，思维链的效果对比：

不使用思维链（错误答案）：

提示词：Tom 有 5 个苹果，他给了 Jane 3 个，然后又买了 2 个，他现在有多少个苹果？

模型回答：4 个（错误，缺乏推理过程）

使用思维链（正确答案）：

提示词：Tom 有 5 个苹果，他给了 Jane 3 个，然后又买了 2 个，他现在有多少个苹果？
让我们一步步思考：

1. Tom 一开始有 5 个苹果
2. 给了 Jane 3 个，所以剩下 $5-3=2$ 个
3. 然后又买了 2 个，所以现在有 $2+2=4$ 个

因此，Tom 现在有 4 个苹果。

5.4 思维链的变体

零样本思维链 (Zero-shot Chain of Thought)：只需在提示后添加“让我们一步步思考” (Let's think step by step)，即可触发模型的推理能力。

5.5 思维链的适用场景

- 数学推理和算术问题
 - 逻辑推理和谜题
 - 多步骤决策
 - 复杂问题分解
 - 需要展示推理过程的任务
-

6. 角色身份提示

6.1 概念

角色身份提示是指通过声明回答由特定专业人员或角色生成，来改善输出质量。

“Since the prompt's role is to leverage the ‘good’ biases that were present in the training set, it benefits from surprising strategies such as stating that the response is generated by a skilled professional.” — The Little Book of Deep Learning (引用 Xu et al., 2023)

6.2 工作原理

训练数据中包含了大量不同角色和身份的文书写作风格。通过声明角色身份，可以激活模型训练数据中与该角色相关的“好偏置”，从而提升输出质量。

6.3 案例

基础版本：

请解释什么是过拟合，以及如何避免它。

增强版本（角色身份）：

你是一位资深的数据科学家。请解释什么是过拟合，以及如何避免它。

高级版本：

Pretend you're an expert machine learning engineer with 10 years of experience in production systems. Explain overfitting, its causes, and practical mitigation strategies used in industry.

6.4 诚实/不诚实行为识别

通过对比模型在不同身份声明下的激活差异，可以研究与诚实相关的行为：

Pretend you're an honest person making statements about the world.
[陈述内容]

Pretend you're a dishonest person making statements about the world.
[陈述内容]

7. 检索增强生成（RAG）提示

7.1 概念

检索增强生成（Retrieval-Augmented Generation, RAG）是将提示词工程与外部知识库相结合的一种技术。它通过提示词作为智能接口，将用户自然语言问题与外部知识连接起来。

“Prompt engineering can also be put to use to connect a language model to an external knowledge base. It plays the role of a smart interface that allows the end user to formulate questions in natural language and get back a response that combines information that is not encoded in the model’s parameters.” — The Little Book of Deep Learning

7.2 工作原理

RAG 的工作流程如下：

1. **检索阶段**：使用嵌入模型检索与用户查询语义相关的文档
2. **拼接阶段**：将检索到的文档与指令拼接成一个完整的提示
3. **生成阶段**：生成模型基于拼接后的提示，产生结合外部知识的响应

7.3 RAG 提示模板

基础模板：

请根据以下参考文档回答用户的问题。如果文档中没有相关信息，请明确说明。

参考文档：
[检索到的文档内容]

用户问题：[用户查询]

请基于上述参考文档给出准确、简洁的回答。

高级模板：

你是一个知识检索助手。你的任务是基于提供的上下文信息回答用户问题。

【上下文】
{context}

【用户问题】
{question}

【要求】

1. 仅基于上下文信息回答
2. 如果上下文不足以回答问题，请明确说明"根据提供的资料，无法回答"
3. 不要添加不在上下文中的信息
4. 回答应简洁、准确

【回答】

7.4 RAG 的关键要点

- **检索质量决定回答质量**：检索到的文档必须与查询相关
 - **提示结构影响整合效果**：清晰的指令有助于模型正确使用检索结果
 - **上下文长度限制**：检索到的文档总长度不能超过模型的上下文窗口
 - **来源标注**：在回答中标注信息来源可以增加可信度
-

8. 上下文长度与提示设计

8.1 上下文长度限制

语言模型的**上下文大小 (context size)** ——即模型能处理的 token 数量——直接决定了提示中能提供的信息量。

“The context size of a language model, that is, the number of tokens it can operate on, directly modulates the quantity of information that can be provided in the prompt.” — The Little Book of Deep Learning

8.2 上下文长度的计算约束

上下文长度主要受标准注意力模型计算成本的限制，注意力机制的计算复杂度与上下文大小呈**二次方关系**。

8.3 提示设计中的长度策略

- **优先使用关键信息**：在有限的上下文内，优先提供最相关的信息
 - **分层提示**：先提供概要，再逐步深入细节
 - **示例数量控制**：根据任务复杂度和上下文空间，控制示例数量
 - **RAG 文档裁剪**：在使用 RAG 时，裁剪检索到的文档以保留最相关部分
-

9. 提示词设计最佳实践

9.1 核心原则

原则

清晰明确

结构化

示例引导

分步推理

角色声明
约束条件
迭代优化

9.2 常见问题与解决方案

问题

模型回答偏离主题
输出格式不一致
回答包含错误信息
回答过于笼统
模型忽略部分指令

9.3 提示词调试流程

1. **明确目标**：确定你希望模型完成的具体任务
2. **编写初版提示**：遵循清晰、结构化的原则
3. **测试输出**：评估模型回答的质量
4. **分析偏差**：找出输出与期望之间的差距
5. **优化提示**：根据分析结果调整提示词
6. **重复测试**：迭代优化直到满意

9.4 进阶技巧组合

对于复杂任务，可以组合使用多种提示技巧：

示例：组合使用角色身份 + 思维链 + 少量样本

你是一位资深的数据分析师。请逐步分析以下销售数据，并给出建议。

【分析步骤】

1. 识别数据中的关键趋势
2. 找出异常值
3. 分析可能的原因
4. 提出数据驱动的建议

【示例分析】

数据：Q1 销售额 100 万，Q2 销售额 120 万，Q3 销售额 115 万
分析：

1. 趋势：Q1 到 Q2 增长 20%，Q2 到 Q3 下降 4.2%
2. 异常值：Q3 销售额下降，但幅度不大
3. 可能原因：季节性因素或市场竞争
4. 建议：进一步分析 Q3 的客户流失率和市场活动

【需要分析的数据】

[具体数据]

10. 参考文献

本手册内容基于以下知识库资料整理：

1. **The Little Book of Deep Learning** — 涵盖提示词工程、思维链、少量样本提示、RAG 等核心概念
2. **Introduction to AI Safety, Ethics, and Society** — 涵盖少量样本学习、零样本学习、上下文学习等理论基础
3. **ML Systems Vol.1 & Vol.2** — 涵盖 RAG 基础设施、向量检索等工程实践

学术引用

- Sahoo, P., Singh, A., Saha, S., et al. *A Systematic Survey of Prompt Engineering in Large Language Models: Techniques and Applications*. CoRR, abs/2402.07927, 2024.
 - Wei, J., Wang, X., Schuurmans, D., et al. *Chain of Thought Prompting Elicits Reasoning in Large Language Models*. CoRR, abs/2201.11903, 2022.
 - Kojima, T., et al. *Large Language Models are Zero-Shot Reasoners*. 2022.
 - Xu, B., Yang, A., Lin, J., et al. *ExpertPrompting: Instructing Large Language Models to be Distinguished Experts*. CoRR, abs/2305.14688, 2023.
 - Lewis, P., Perez, E., Piktus, A., et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. CoRR, abs/2005.11401, 2020.
 - Brown, T., et al. *Language Models are Few-Shot Learners*. CoRR, abs/2005.14165, 2020.
-

手册说明：本手册基于知识库中的多份学术资料整理而成，内容涵盖提示词工程的核心概念、技术方法和实践案例。资料来源于《The Little Book of Deep Learning》、《Introduction to AI Safety, Ethics, and Society》等权威文献。